Progettazione logica delle basi di dati

Ristrutturazione dello schema Entità–Relazione

Prof. Fedeli Massimo - Tutti i diritti riservati

Perché non basta tradurre lo schema ER

Lo schema ER consente costrutti che il modello relazionale non supporta direttamente.

Ad esempio:

- attributi multivalore;
- attributi composti;
- gerarchie ISA;
- generalizzazioni.

Per questo è necessaria una fase di ristrutturazione.

Il concetto di carico applicativo

Quando si progetta un database è fondamentale sapere come verrà usato.

Il **carico applicativo** descrive:

- quali operazioni vengono eseguite;
- con quale frequenza;
- su quali dati.

Queste informazioni influenzano le scelte progettuali.

Perché il carico applicativo è importante

Due schemi equivalenti dal punto di vista dei dati possono avere **prestazioni** molto diverse.

Conoscere il carico applicativo permette di:

- valutare i costi delle operazioni;
- decidere se mantenere o eliminare ridondanze;
- migliorare l'efficienza complessiva del sistema.

Schema ER di esempio

Consideriamo uno schema semplificato con impiegati e dipartimenti.

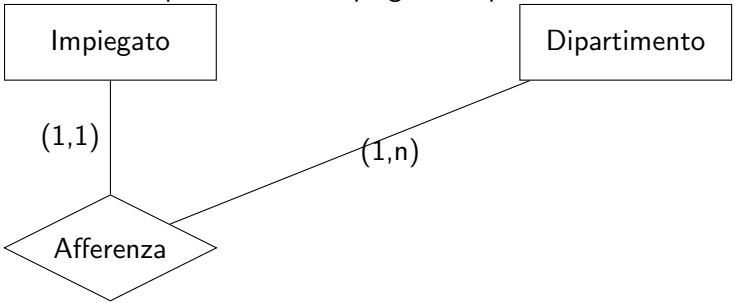

Ogni impiegato lavora in un solo dipartimento, mentre un dipartimento può avere più impiegati.

Ristrutturazione dello schema ER

La ristrutturazione consiste nel modificare lo schema ER per renderlo **compatibile** con il modello relazionale.

Non si perdono informazioni, ma:

- si semplifica la struttura;
- si rendono espliciti i vincoli;
- si prepara lo schema alla traduzione.

Attività della ristrutturazione

Le principali attività della ristrutturazione sono:

1. analisi delle ridondanze;
2. eliminazione degli attributi multivalore;
3. eliminazione degli attributi composti;
4. eliminazione di ISA e generalizzazioni;
5. scelta degli identificatori principali.

Ridondanza: definizione

Una **ridondanza** è un'informazione che può essere derivata da altre informazioni già presenti nello schema.

Esempio:

- **numero di abitanti** di una città;
- **derivabile** dal numero di persone residenti.

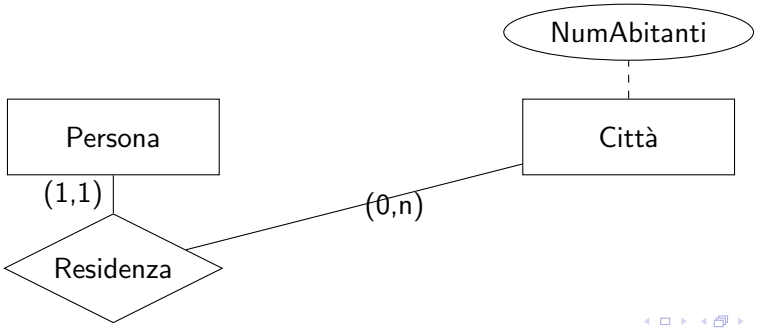

Ridondanza: osservazione

Osservazione: l'attributo *NumAbitanti* è ridondante perché può essere **calcolato** contando le persone collegate alla città tramite la relazione *Residenza*

Vantaggi e svantaggi delle ridondanze

Mantenere una ridondanza può avere effetti diversi sulle prestazioni e sulla gestione dei dati.

Vantaggi (lettura):

- interrogazioni più veloci;
- meno accessi ai dati.

Svantaggi (aggiornamento):

- aggiornamenti più complessi;
- rischio di incoerenza;
- maggiore occupazione di spazio.

In sintesi: la ridondanza favorisce le interrogazioni, ma rende più delicata la gestione degli aggiornamenti.

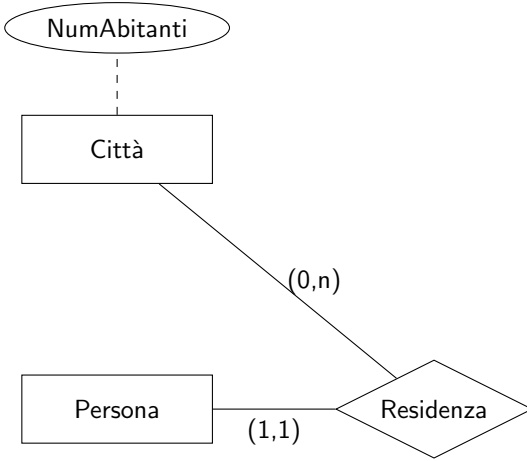

Lettura:

Esempio di ristrutturazione: schema iniziale

Consideriamo un sistema che gestisce persone e città di residenza.

Nello schema iniziale **non è presente alcuna ridondanza**: il numero di abitanti di una città può essere **calcolato** contando le persone residenti.

- Ogni persona risiede in una sola città
- Una città può avere molte persone
- Il numero di abitanti non è memorizzato

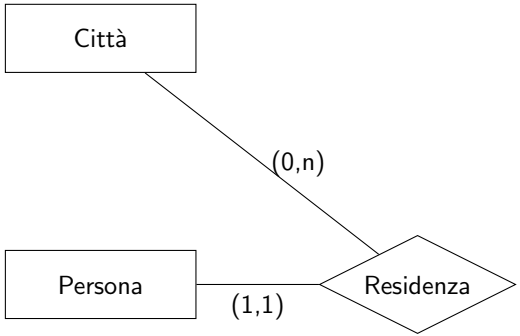

Osservazione: lo schema è corretto ma può risultare costoso per interrogazioni frequenti sul numero di abitanti.

Valutazione dei costi: schema senza ridondanza

Per valutare l'efficienza dello schema analizziamo **volumi dei dati** e **accessi alle operazioni**.

Tabella dei volumi

Costrutto	Numero di istanze
Persona	1.000.000
Città	200
Residenza	1.000.000

Operazione di interesse

Stampare i dati di una città con il numero di abitanti (eseguita 2 volte al giorno).

Tabella degli accessi

Costrutto	Accessi in lettura
Residenza	5.000
Persona	5.000

Schema ristrutturato con ridondanza

Per migliorare le prestazioni delle interrogazioni, si decide di **introdurre una ridondanza**.

Si aggiunge all'entità *Città* l'attributo *NumAbitanti*, aggiornato ogni volta che una persona cambia residenza.

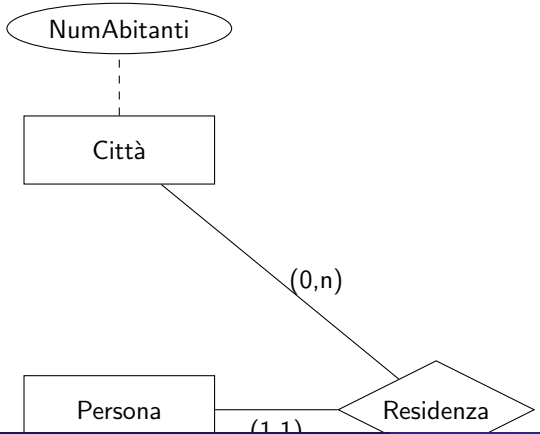

Nuova valutazione dei costi

- Lettura numero abitanti:
  - 1 solo accesso alla tabella Città
- Inserimento di una persona:
  - 1 scrittura su Persona
  - 1 aggiornamento su Città

Conclusione: meno costi in lettura, più costi in aggiornamento.

Confronto dei costi: con e senza ridondanza

Confrontiamo ora i costi delle operazioni principali nei due schemi.

Operazioni considerate

- O1: inserimento di una nuova persona
- O2: lettura dei dati di una città con numero di abitanti

Confronto degli accessi

Operazione	Senza ridondanza	Con ridondanza
O1 – Inserimento persona	1 scrittura	2 scritture
O2 – Lettura abitanti	10.000 letture	1 lettura

Interpretazione

- la ridondanza aumenta il costo degli aggiornamenti;
- riduce drasticamente il costo delle interrogazioni;
- conviene se le letture sono molto più frequenti delle scritture.

Conclusione progettuale: la scelta dipende dal carico applicativo, non solo dalla struttura dello

Contro-esempio: carico dominato dagli aggiornamenti

Consideriamo ora un contesto applicativo diverso, in cui le **operazioni di aggiornamento sono molto frequenti**, mentre le interrogazioni aggregate sono rare.

Scenario tipico:

- sistema anagrafico o gestionale;
- frequenti inserimenti, cancellazioni e cambi di residenza;
- raramente si richiede il numero totale di abitanti.

In questo caso la presenza di una ridondanza può diventare **uno svantaggio**.

Valutazione dei costi: aggiornamenti frequenti

Analizziamo volumi e operazioni nel nuovo scenario.

Tabella dei volumi

Costrutto	Numero di istanze
Persona	500.000
Città	200
Residenza	500.000

Operazioni di interesse

- O1: inserimento o modifica residenza (3.000 operazioni al giorno)
- O2: lettura numero abitanti di una città (1 volta al giorno)

Il carico applicativo è chiaramente sbilanciato sugli aggiornamenti.

Confronto dei costi: eliminare la ridondanza

Confrontiamo i costi nei due schemi.

Operazione	Con ridondanza	Senza ridondanza
O1 – Aggiornamento residenza	2 scritture	1 scrittura
O2 – Lettura abitanti	1 lettura	5.000 letture

Valutazione complessiva

- gli aggiornamenti sono molto frequenti;
- la lettura aggregata è rara;
- il costo aggiuntivo degli aggiornamenti non è giustificato.

Decisione progettuale: in questo scenario è preferibile **eliminare il campo calcolato** e calcolare il valore solo quando necessario.

Attributi multivalore

Un **attributo multivalore** è un attributo che può assumere più valori per una stessa entità.

Esempi tipici:

- numeri di telefono;
- indirizzi email;
- lingue conosciute.

Perché gli attributi multivalore non sono ammessi

Nel modello relazionale:

- ogni campo di una tabella deve contenere un solo valore;
- non sono ammesse liste o insiemi di valori.

Per questo gli attributi multivalore devono essere eliminati.

Eliminazione di un attributo multivalore

L'attributo multivalore viene trasformato in una relazione separata.

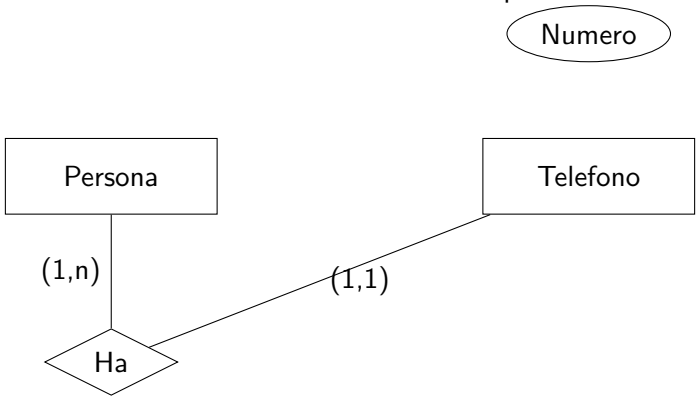

Ogni valore dell'attributo diventa una nuova istanza.

Attributi multivalore di una relazione

Un attributo multivalore può appartenere anche a una **relazione**, non solo a un'entità.

Esempio:

- un impiegato partecipa a un progetto;
- per ogni partecipazione possono esserci più *ruoli* svolti.

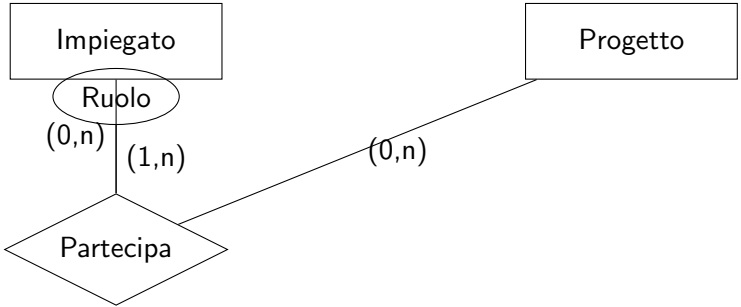

Problema: il modello relazionale non ammette attributi multivalore, nemmeno quando sono associati a una relazione.

Eliminazione: trasformare la relazione in entità

Per eliminare un attributo multivalore di una relazione, è necessario **trasformare la relazione stessa in un'entità**.

La relazione *Partecipa* diventa una nuova entità autonoma, che rappresenta ogni singola partecipazione.

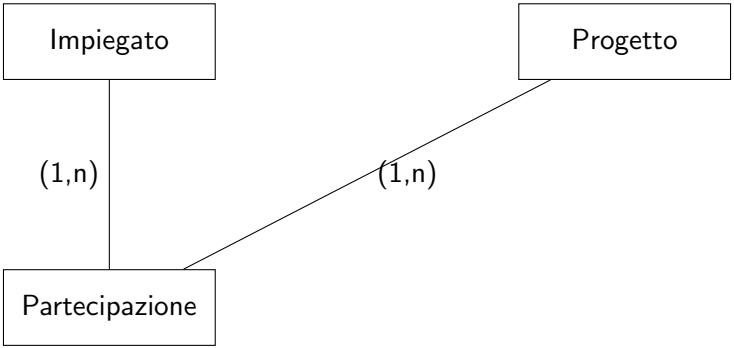

Eliminazione completa dell'attributo multivalore

A questo punto l'attributo multivalore *Ruolo* può essere eliminato trasformandolo in una relazione separata.

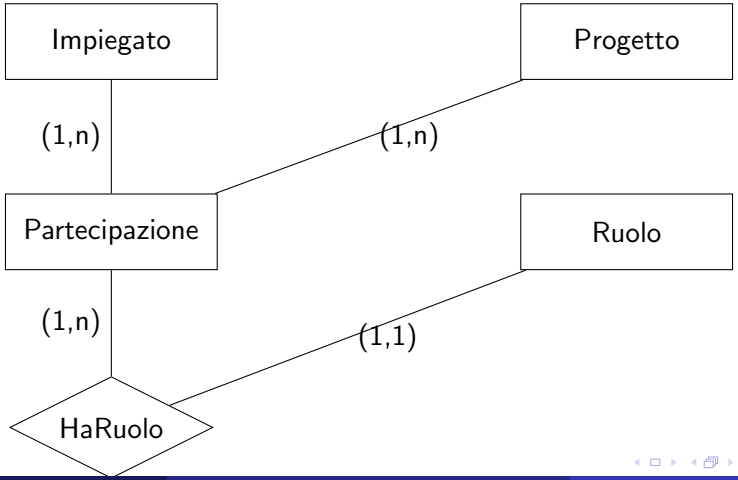

Eliminazione di attributi multivalore di una relazione

Procedura riassuntiva in 3 passi

1. **Individuare l'attributo multivalore** associato alla relazione (es. *Ruolo* nella relazione *Partecipa*).
2. **Trasformare la relazione in un'entità** ogni istanza della relazione diventa un oggetto autonomo (es. *Partecipa* $\rightarrow$ *Partecipazione*).
3. **Trasformare l'attributo multivalore in una relazione** introducendo una nuova entità per il dominio dei valori (es. *Ruolo* come entità collegata a *Partecipazione*).

Risultato

Lo schema non contiene più attributi multivalore ed è completamente compatibile con il modello relazionale.

Attributi composti

Un **attributo composto** è formato da più sotto-attributi.

Esempio:

- Indirizzo = Via, Numero, CAP.

Nel modello relazionale gli attributi devono essere atomici.

Eliminazione degli attributi composti

Un attributo composto viene eliminato:

- scomponendolo nei suoi **attributi elementari**;
- oppure trasformandolo in una **nuova entità**.

La scelta dipende dalla cardinalità e dall'uso dell'attributo.

Esempio 1: scomposizione di un attributo composto

Consideriamo l'attributo composto *Indirizzo* associato all'entità *Persona*.

L'attributo *Indirizzo* è formato da più parti: *Via*, *Numero* e *CAP*.

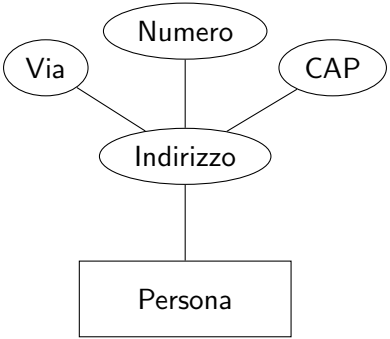

Trasformazione: l'attributo composto viene eliminato e i suoi componenti diventano attributi diretti dell'entità.

Esempio 2: attributo composto trasformato in entità

Se l'attributo composto è opzionale oppure viene riutilizzato, può essere opportuno trasformarlo in una nuova entità.

Esempio: una persona può avere *al più un indirizzo*, ma l'indirizzo è un'informazione autonoma.

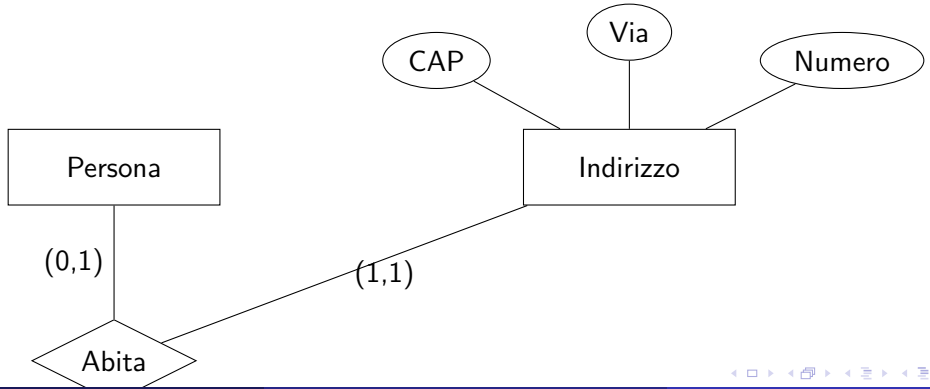

Motivazioni della scelta progettuale

Quando si elimina un attributo composto, la scelta della trasformazione non è arbitraria, ma dipende da precise **motivazioni progettuali**.

Motivazioni per la scomposizione in attributi elementari

- l'attributo è sempre presente per ogni istanza dell'entità;
- i componenti sono strettamente legati e usati insieme;
- non è necessario gestire l'attributo separatamente;
- si vuole mantenere uno schema semplice e compatto.

Motivazioni per la trasformazione in nuova entità

- l'attributo è opzionale o può mancare;
- i suoi componenti possono essere usati indipendentemente;
- l'attributo rappresenta un concetto autonomo del dominio;
- è utile evitare valori nulli nell'entità principale.

Conclusione

Relazioni ISA

Le **relazioni ISA** rappresentano specializzazioni tra entità.

Esempio:

- Studente è una Persona;
- Docente è una Persona.

Nel modello ER sono molto naturali.

Problema delle ISA nel modello relazionale

Il modello relazionale non supporta direttamente le gerarchie.

È quindi necessario:

- eliminare le ISA;
- esprimere i vincoli in modo esplicito.

Eliminazione delle relazioni ISA

La relazione ISA viene sostituita da una **relazione binaria** tra l'entità figlia e l'entità padre.

Dopo la trasformazione:

- le entità diventano **disgiunte**;
- la specializzazione non è più implicita;
- la gerarchia è rappresentata tramite relazioni.

Osservazione: i vincoli di specializzazione (vincoli ISA) vengono espressi separatamente.

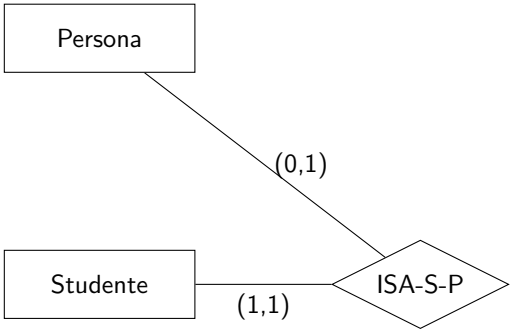

Studente è specializzazione di Persona

Perché eliminare la ISA senza collassare le entità

L'eliminazione di una relazione ISA **non** comporta l'unione delle entità coinvolte in un'unica entità.

Perché non collassare le entità in una sola

- le entità figlie possono avere attributi diversi e specifici;
- non tutte le istanze dell'entità padre appartengono alle entità figlie;
- il collasso introdurrebbe molti valori nulli;
- si perderebbe l'informazione sulla specializzazione.

Perché usare una relazione binaria

- mantiene separati i concetti del dominio;
- rende esplicita la specializzazione;
- consente di esprimere correttamente i vincoli ISA;
- prepara lo schema alla traduzione nel modello relazionale.

Idea chiave

Quando è opportuno collassare le entità in una relazione ISA

In alcuni casi particolari, le entità collegate da una relazione ISA possono essere **collassate in un'unica entità**.

Condizioni necessarie per il collasso

- tutte le istanze dell'entità padre appartengono a una sola entità figlia (generalizzazione **completa**);
- le entità figlie sono **mutuamente esclusive** (disgiunte);
- gli attributi specifici delle entità figlie sono pochi;
- il numero di valori nulli rimane contenuto.

Modalità di collasso

- si crea un'unica entità con tutti gli attributi;
- si introduce un attributo *tipo* (discriminante);
- il valore del discriminante determina quali attributi sono significativi.

Avvertenza

Esempio grafico: collasso di una relazione ISA

Consideriamo una generalizzazione **completa e disgiunta**, in cui ogni istanza dell'entità padre appartiene esattamente a una sola entità figlia.

Schema con ISA

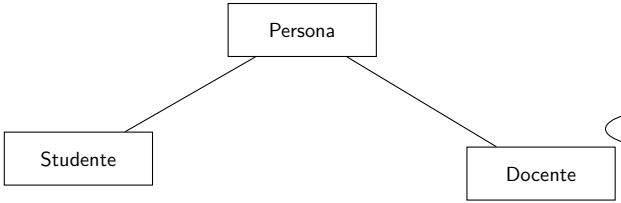

Schema dopo il collasso

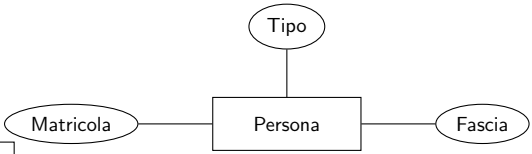

Tipo = Studente / Docente

Generalizzazione completa e disgiunta

Osservazione: il collasso è possibile perché ogni persona è *o studente o docente*, senza eccezioni.

Gestione delle gerarchie ISA: le tre strategie possibili

Quando si incontra una relazione ISA, esistono **tre strategie** di ristrutturazione possibili.

1. **Collassare le entità figlie nel padre** (un'unica entità con discriminante);
2. **Sostituire la ISA con relazioni binarie** mantenendo padre e figlie separate;
3. **Eliminare l'entità padre** trasferendo i suoi attributi alle entità figlie.

Obiettivo

Scegliere la strategia che rappresenta meglio il dominio applicativo ed è più adatta all'uso dei dati.

Guida decisionale: domande da porsi

Per scegliere la strategia corretta, è utile rispondere alle seguenti domande, in ordine.

1. **La generalizzazione è completa?** Tutte le istanze del padre appartengono a una figlia?
2. **Le entità figlie sono disgiunte?** Ogni istanza appartiene a una sola entità figlia?
3. **Gli attributi specifici delle figlie sono pochi?**
4. **L'entità padre ha un ruolo autonomo nel dominio?**

Le risposte a queste domande indirizzano la scelta progettuale.

Schema decisionale per la gestione di una ISA

- **Se la generalizzazione è completa e disgiunta**
  - e gli attributi specifici sono pochi → **collassare le entità figlie nel padre**;
- **Se il padre rappresenta un concetto autonomo**
  - oppure la generalizzazione è parziale → **sostituire la ISA con relazioni binarie**;
- **Se l'entità padre non ha significato autonomo**
  - e serve solo a raccogliere attributi comuni → **eliminare il padre e trasferire gli attributi**;

Regola d'oro

Non scegliere in base alla semplicità dello schema, ma in base al **significato dei dati**.

Schema iniziale: gerarchia ISA

Consideriamo uno schema con una relazione di specializzazione tra un'entità padre e due entità figlie.

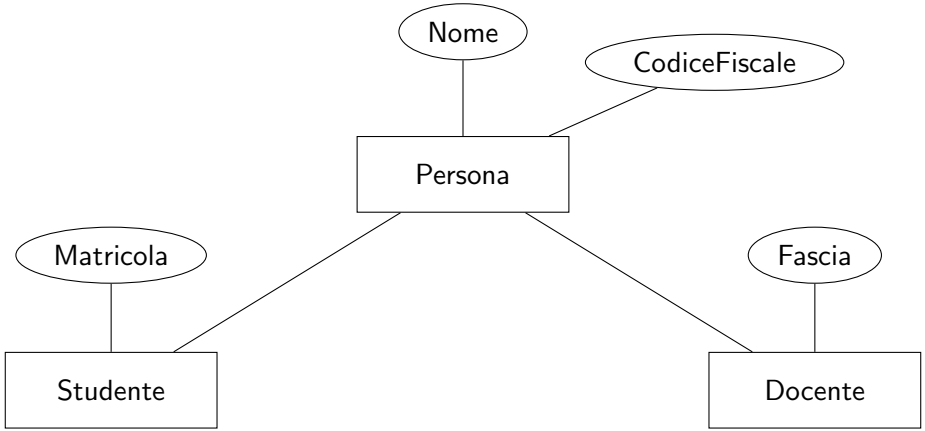

Osservazione:

Esempio 1: collasso delle entità figlie nel padre

Caso: generalizzazione completa e disgiunta, con pochi attributi specifici.

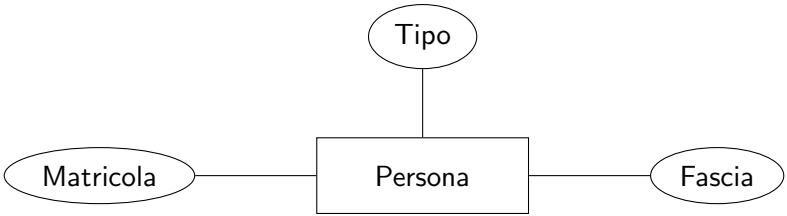

Spiegazione:

- tutte le persone sono o studenti o docenti;
- un attributo *Tipo* discrimina il ruolo;
- soluzione compatta, ma con possibili valori nulli.

Esempio 2: sostituzione della ISA con relazioni binarie

Caso: entità padre con significato autonomo e generalizzazione non necessariamente completa.

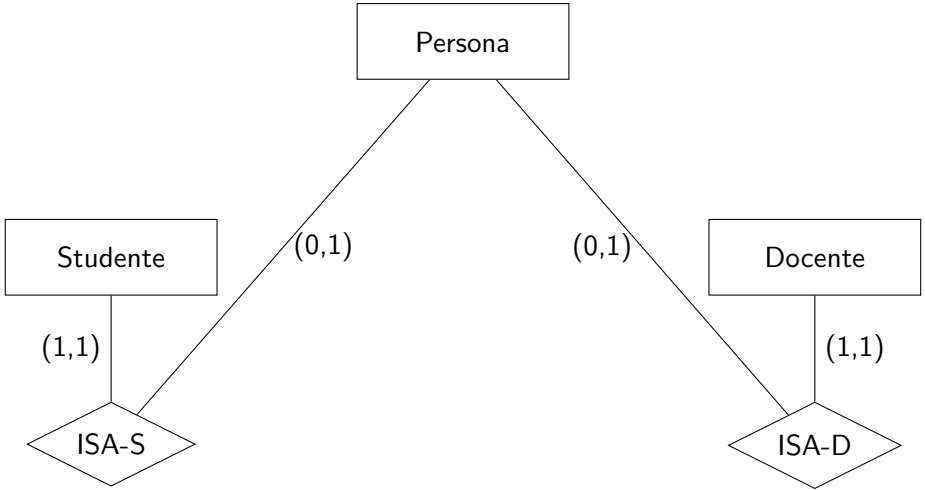

Esempio 3: eliminazione dell'entità padre

Caso: l'entità padre non ha significato autonomo e serve solo a raccogliere attributi comuni.

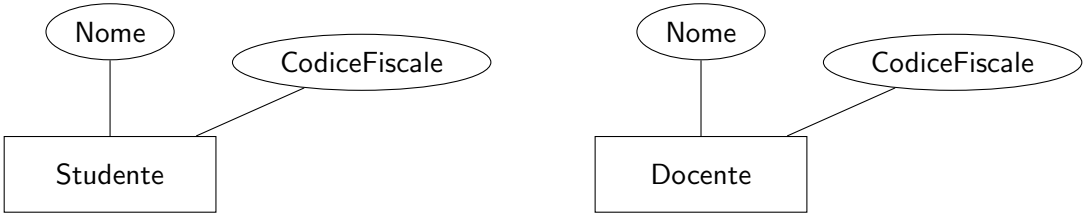

Spiegazione:

- gli attributi del padre sono duplicati;
- schema più semplice;
- maggiore ridondanza, minore espressività.

Identificatori delle entità

Un **identificatore** è un insieme di attributi che permette di distinguere univocamente ogni istanza di un'entità.

Ogni entità deve avere:

- almeno un identificatore;
- un identificatore principale.

Scelta dell'identificatore principale

L'identificatore principale dovrebbe essere:

- semplice;
- stabile nel tempo;
- usato frequentemente nelle operazioni.

Se necessario, si introduce un **codice artificiale**.

Schema ER ristrutturato

Al termine della ristrutturazione, lo schema ER:

- non contiene attributi multivalore;
- non contiene attributi composti;
- non contiene ISA o generalizzazioni;
- assegna un identificatore principale a ogni entità.

Preparazione alla traduzione relazionale

Lo schema ER ristrutturato è il punto di partenza per la traduzione nel modello relazionale.

Nella fase successiva:

- entità $\rightarrow$ tabelle;
- relazioni $\rightarrow$ tabelle;
- attributi $\rightarrow$ colonne.

Riepilogo finale

La ristrutturazione dello schema ER è una fase fondamentale della progettazione logica.

Permette di:

- mantenere il significato dei dati;
- rispettare le regole del modello relazionale;
- progettare database corretti ed efficienti.

Riferimenti bibliografici

I contenuti presentati si basano sui principali testi e materiali di riferimento per la progettazione delle basi di dati.

- C. Batini, S. Ceri, S. Navathe, *Fondamenti di basi di dati*, McGraw-Hill Education.
- A. Silberschatz, H. Korth, S. Sudarshan, *Database System Concepts*, McGraw-Hill.
- P. Atzeni, S. Ceri, S. Paraboschi, R. Torlone, *Basi di dati – Modelli e linguaggi di interrogazione*, McGraw-Hill.
- Materiale didattico e dispense di corso sulla progettazione concettuale e logica delle basi di dati.

I diagrammi e gli esempi sono stati adattati a fini didattici.